

Tesina

Licenciatura en Estadística

Análisis de comentarios en redes sociales con latent Dirichlet allocation



Facultad de Ciencias Económicas y Estadística

Alumna: Alfonsina Badin

Director: Ignacio Evangelista

2025

Índice

1	Agradecimientos	3
2	Resumen	4
3	Introducción	5
4	Objetivos	7
4.1	Objetivo general	7
4.2	Objetivos específicos	7
5	Metodología	8
5.1	Estadística Bayesiana	8
5.1.1	Modelos hacia adelante	9
5.1.2	Modelos hacia atrás	11
5.1.3	Modelos jerárquicos	11
5.1.4	Métodos de aproximación	13
5.1.4.1	Markov chain Monte Carlo	14
5.1.4.2	Muestreo de Gibbs	14
5.2	Machine learning	16
5.3	Procesamiento de Lenguaje Natural (NLP)	17
5.3.1	Recolección de datos	18
	Uso de conjuntos de datos públicos	18
	Obtención de datos de internet	18
	Combinación de fuentes de datos	18
5.3.2	Limpieza de texto	18
	Pasos preliminares	19
	Tokenización	19
	Normalización de unicode	19
	Eliminación de stopwords	20
	Corrección ortográfica	20
	Corrección ortográfica empleando distancia de Levenshtein-Damerau	21
	Lematización	23

5.3.3	Representación de texto	24
	Representación vectorial	24
	One-Hot Encoding	25
	Bag of words	26
	TF-IDF	27
	Embeddings	28
	Word2Vec	28
	GloVe	29
	BERT	29
6	Bibliografía	31

1 Agradecimientos

2 Resumen

3 Introducción

A lo largo de los años, las redes sociales se han convertido en el medio de comunicación más utilizado. Diariamente, los usuarios ingresan a ellas para conversar con otras personas, dar a conocer sus puntos de vista, compartir experiencias, informarse sobre las últimas noticias y entretenerse.

En el año 2020, a raíz de la pandemia mundial por COVID-19, hubo un tipo de contenido que se popularizó con gran velocidad: el *streaming*. El *streaming* es una combinación de radio y televisión, que se transmite en vivo en una plataforma gratuita (YouTube o Twitch) y luego es publicado *On-Demand* para que el usuario pueda verlo fuera de su horario habitual si así lo desea. Por lo general el formato consta de un panel de conductores que charlan de tópicos comunes para la audiencia, generando debates interesantes con los que los usuarios se pueden llegar a identificar. Dentro de cada canal de *streaming* se transmiten distintos programas que tienen un perfil particular y objetivos diferentes ya que su contenido puede variar en entretenimiento, humor, chimentos, noticias, etc.

Su popularidad se debe a que es un contenido gratuito, cercano y que genera una **comunidad** entre los conductores y sus oyentes, quienes no sólo interactúan en vivo a través de un *chat* sino que dejan sus comentarios en otras redes sociales: Instagram, TikTok, YouTube, entre otros.

Al publicar los programas *On-Demand*, los canales de *streaming* acceden a un recurso valioso que refleja la opinión de sus oyentes: los comentarios de YouTube. El análisis de estos textos puede resultar en conclusiones interesantes para los canales ya que permite un entendimiento de los sentimientos que tiene su comunidad con respecto a cada contenido.

Para llevar a cabo este análisis, el presente informe utiliza **latent Dirichlet allocation (LDA)**, una técnica de aprendizaje automático no supervisado que clasifica automáticamente los textos en diferentes categorías o temas según las características del corpus. Esta metodología permite detectar patrones temáticos recurrentes en grandes volúmenes de datos textuales, como los comentarios de YouTube, y extraer información valiosa.

LDA se basa en un modelo probabilístico generativo y es especialmente útil para modelar datos discretos como textos. Es un modelo bayesiano jerárquico de tres niveles, en el cual cada documento (en este caso, cada comentario) se representa como una mezcla de temas, y cada tema se define como una mezcla de palabras. En este sentido, LDA no solo agrupa comentarios en función de temas compartidos, sino que también asigna probabilidades a cada palabra dentro de cada tema, proporcionando una representación explícita y estructurada del contenido del corpus.

Esta capacidad de modelar documentos como combinaciones de múltiples temas lo hace

particularmente adecuado para analizar la diversidad temática de los comentarios de YouTube. Por ejemplo, un comentario podría estar relacionado en un 60% con el tema “entretenimiento” y en un 40% con el tema “noticias”, lo que permite identificar la interacción entre los intereses de los usuarios.

Esta tesina tiene por objeto de estudio la técnica latent Dirichlet allocation. Se brinda una introducción al tema, abarcando las definiciones básicas, sus componentes, sus variantes, sus ventajas y limitaciones y sus campos de aplicación. Se incluyen también los conceptos teóricos necesarios para comprender la metodología. Adicionalmente, se presenta la aplicación del modelo en comentarios de redes sociales.

4 Objetivos

4.1 Objetivo general

El objetivo general del presente proyecto es profundizar en el estudio y aplicación del modelo latent Dirichlet allocation (LDA) para la identificación de tópicos o categorías.

4.2 Objetivos específicos

- Comprender las bases del procesamiento de lenguaje natural (NLP por sus siglas en inglés) y las técnicas de representación computacional de texto.
- Mencionar los desafíos y limitaciones que conlleva el ajuste de LDA y propuestas que han surgido para contrarrestar dichos inconvenientes.
- Aplicar LDA en un conjunto comentarios en español (argentino) en la red social YouTube para comprender las opiniones de los oyentes.

5 Metodología

5.1 Estadística Bayesiana

La estadística bayesiana es un enfoque que, mediante el uso del teorema de Bayes, actualiza la probabilidad de una hipótesis a medida que se obtienen más datos, combinando las observaciones con las creencias previas. A diferencia de la estadística frecuentista, que interpreta las probabilidades como frecuencias relativas en un gran número de ensayos, la bayesiana trata la probabilidad como un grado de creencia o confianza.

Kruschke presenta una analogía muy clara para entender el concepto: si al abrir una ventana se ve el suelo mojado, es natural creer que ha llovido. Sin embargo, al abrir aún más la ventana se observa que los autos están secos y que el agua es solo un charco junto a las plantas del vecino. La idea de la lluvia pierde toda su fuerza y la creencia cambia a que el vecino regó las plantas. De esto trata precisamente la estadística bayesiana: es la reasignación de la credibilidad en función de nueva evidencia.

Teorema de Bayes: Sea θ una hipótesis o conjetura que se tiene sobre el fenómeno en estudio e y evidencia o nueva información, el grado de incertidumbre (o credibilidad) de esa hipótesis se puede actualizar teniendo en cuenta la nueva evidencia.

$$\underbrace{p(\theta|y)}_{\text{Distribución a posteriori}} = \frac{\overbrace{p(y|\theta)}^{\text{Verosimilitud}} \overbrace{p(\theta)}^{\text{Distribución a priori}}}{\underbrace{p(y)}_{\text{Evidencia}}}$$

Donde:

- Distribución *a posteriori* ($p(\theta|y)$): densidad condicional que describe la creencia del valor real de θ luego de haber observado y .
- Verosimilitud ($p(y|\theta)$): describe la certeza de que y sea el resultado del estudio si el conocimiento de θ fuera acertado.
- Distribución *a priori* ($p(\theta)$): describe la creencia inicial que se asignó a θ antes de observar y . Esta asignación puede estar basada en investigaciones previas, en conocimiento personal o determinada desde la ignorancia absoluta.
- Evidencia ($p(y)$): es la probabilidad marginal de los datos y actúa como constante de normalización para procurar que $\int p(\theta|y)d\theta = 1$ ya que $p(y) = \int_{\Theta} p(y|\theta)p(\theta)d\theta$.

Dado que los datos y ya fueron observados, la distribución *a posteriori* es una función de θ y resulta

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$

Continuando con la analogía de la ventana, $p(\theta)$ es la probabilidad de que haya llovido y $p(y|\theta)$ es la probabilidad de que los autos estén secos y la humedad sea de un charco habiendo llovido. $p(\theta|y)$ es la creencia de la lluvia, dado lo observado al abrir más la ventana.

La media de la distribución *a posteriori* resulta en un promedio ponderado de la media previa y la media de la muestra observada. Este comportamiento determina la forma de la distribución *a posteriori* y la ubicación de sus medidas descriptivas. La ponderación mencionada depende de la fuerza de la creencia inicial y de la cantidad de datos observados. En la Figura 1 se puede observar el cambio en la distribución *a posteriori* en distintos casos.




Figura 1: El efecto del peso de la evidencia en la distribución *a posteriori*

5.1.1 Modelos hacia adelante

Los modelos hacia adelante parten de suposiciones sobre los parámetros o las distribuciones que generan los datos y buscan modelar cómo estos datos podrían haberse producido. Es un paso fundamental para

comprender el camino por el que pasa un dato para ser observado por el modelo y permite construir $p(y, \theta) = p(\theta)p(y|\theta)$. Este enfoque es útil para simular datos y predecir resultados futuros basados en los modelos probabilísticos definidos calculando la distribución predictiva *a posteriori* $p(\tilde{y}|y) = \int p(\tilde{y}|\theta)p(\theta|y)d\theta$.

Para ilustrarlo, se considera un canal de YouTube del que se tiene conocimiento de su público (mediante los comentarios). Se sabe que la comunidad opina desde dos puntos de vista: apoyo y crítica. Estas temáticas están compuestas por las siguientes palabras:

$$\beta_{\text{apoyo}} = \{\text{"orgullo"} : 0.4, \text{"llorar"} : 0.3, \text{"compañía"} : 0.2, \text{"aguante"} : 0.1\}$$

$$\beta_{\text{crítica}} = \{\text{"mal"} : 0.4, \text{"irrespetuoso"} : 0.3, \text{"absurdo"} : 0.2, \text{"llorar"} : 0.1\}$$

Un usuario vio un video en particular donde se toca un tema sensible para él y, si bien él es un fiel consumidor del contenido del canal, necesita presentar su opinión. Entonces, se define

$$\theta = [40\% \text{ apoyo}, 60\% \text{ crítica}]$$

Con esta composición de comentario entonces, se propone crear uno con 5 palabras siguiendo el siguiente proceso:

Palabra 1:

1. Se selecciona un valor aleatorio que determina el tema de la palabra. Si el valor es menor a 0.6 se selecciona el tema crítica, si no se selecciona apoyo. $z_1 = 0.54 \Rightarrow \text{tema}_1 = \text{Crítica}$.
2. Se toma un valor aleatorio que determina la palabra del tema. Continuando con la lógica anterior, si el valor es menor al peso de cada palabra, se selecciona la misma. $w_1 = 0.49 \Rightarrow \text{palabra}_1 = \text{"irrespetuoso"}$.

Palabra 2:

1. $z = 0.03 \Rightarrow \text{tema}_2 = \text{Crítica}$
2. $w_1 = 0.24 \Rightarrow \text{palabra}_2 = \text{"mal"}$

Palabra 3:

1. $z = 0.81 \Rightarrow \text{tema}_3 = \text{Apoyo}$
2. $w_1 = 0.19 \Rightarrow \text{palabra}_3 = \text{"orgullo"}$

Continuando con el resto de las palabras, se obtiene el comentario

$$\underbrace{\text{"irrespetuoso"}}_{\text{crítica}} \quad \underbrace{\text{mal}}_{\text{crítica}} \quad \underbrace{\text{orgullo}}_{\text{apoyo}} \quad \underbrace{\text{llorar}}_{\text{crítica}} \quad \underbrace{\text{aguante}}_{\text{apoyo}}$$

Este comentario claramente carece de sentido al ojo humano pero es evidente que está cargado, según θ , con cada tema. En la vida real, se conoce el comentario pero no se tiene en claro las intenciones del usuario al comentar ni las palabras que pertenecen a él ni a los temas. El verdadero desafío es descubrir qué parámetros (en este caso $\beta_{\text{apoyo}}, \beta_{\text{crítica}}$ y θ) son los que han afectado en el modelo para la creación del comentario.

5.1.2 Modelos hacia atrás

El modelo hacia atrás, formalmente denominado inferencia bayesiana, es el proceso inverso al modelado generativo. Mientras que el modelo hacia adelante simula datos a partir de parámetros conocidos, el modelo hacia atrás parte de los datos observados (el efecto) para reconstruir las distribuciones de probabilidad de los parámetros latentes que los generaron (la causa). Su objetivo fundamental es derivar la distribución *a posteriori*, actualizando las creencias previas mediante la aplicación del teorema de Bayes.

Para ilustrarlo, se toma el comentario generado en el ejemplo anterior y se intenta buscar o entender qué pasó por la mente del usuario, sabiendo el vocabulario de cada tema β_{apoyo} y $\beta_{\text{crítica}}$.

A cada palabra se le identifica el tema más probable según su peso en el vocabulario: "irrespetuoso mal orgullo llorar aguante". Sumando los casos de cada tema, se obtienen 3 palabras del tema apoyo y 2 para crítica, entonces $\hat{\theta} = [60\% \text{ apoyo}, 40\% \text{ crítica}]$. Se observa que el resultado de $\hat{\theta}$ difiere del θ que generó el mismo comentario, esto se debe a la repetición de la palabra "llorar" en ambos temas y al peso que tiene en cada uno.

5.1.3 Modelos jerárquicos

Cuando se cuenta con datos de muchas fuentes que están relacionadas de alguna manera, se hace uso de los modelos jerárquicos. Estos proveen un marco matemático para describir las dependencias entre múltiples parámetros, de forma que la estimación de un parámetro depende de la estimación de otro(s) parámetro(s).

Un modelo es jerárquico si puede factorizarse en una cadena de dependencias con niveles:

1. Nivel inferior (verosimilitud): describe la distribución de los datos en función de los parámetros.
2. Nivel intermedio (*priori*): describe la distribución de los parámetros que afectan a la verosimilitud. Esta depende de parámetros provenientes de una distribución más grande, definida por hiper-parámetros.
3. Nivel superior (*priori* de los hiper-parámetros): describe la distribución de los hiper-parámetros.

La fuerza de los modelos jerárquicos es su adaptabilidad a distintos casos de estudio ya que se pueden aplicar a modelos con múltiples dependencias (niveles escalables) y a parámetros clasificados según

un agrupamiento. Por ejemplo, para un caso de dos grupos, el modelo jerárquico se vería como en la Figura 2.




Figura 2: Diagrama del flujo de un modelo jerárquico a 3 niveles con dos grupos

La distribución *a posteriori* dependerá de todos los parámetros existentes en el modelo. Sea y_{ij} la observación i -ésima del grupo j , donde $i = \overline{1, n}$ y $j = \overline{1, k}$, se tiene que:

$$\begin{aligned}
 p(\theta, \Psi | y) &\propto p(y | \theta, \Psi) p(\theta, \Psi) \\
 &\propto \left(\prod_{i=1}^n \prod_{j=1}^k p(y_{ij} | \theta_j, \Psi) \right) \left(\prod_{j=1}^k p(\theta_j | \Psi) p(\psi) \right) \\
 &\propto \underbrace{\prod_{i=1}^n \prod_{j=1}^k p(y_{ij} | \theta_j, \Psi)}_{\text{verosimilitud}} \underbrace{\prod_{j=1}^k p(\theta_j | \Psi)}_{\text{priori}} \underbrace{p(\psi)}_{\text{hiper-priori}}
 \end{aligned}$$

Para ilustrar el concepto con el caso del usuario y su comentario en YouTube, se presenta el modelo de la Figura 3. Para cada comentario, se asigna una mezcla de temas θ y, para cada posición $i = \overline{1, n}$ en el comentario:

1. Se elige un tópico según θ ,
2. se elige una palabra del tópico según β .

Al definir un modelo jerárquico se establecen dependencias condicionales entre parámetros e hiperparámetros. Sin embargo, surge un desafío matemático inmediato: al multiplicar la distribución *a priori* por la verosimilitud (según la Regla de Bayes), la expresión resultante suele ser matemáticamente intratable, dificultando la obtención de la distribución *a posteriori*. Para sortear este obstáculo, la estadística




Figura 3: Diagrama del flujo de un modelo jerárquico a 3 niveles con dos grupos

bayesiana recurre a las distribuciones conjugadas.

Se dice que una familia de distribuciones es conjugada respecto a una función de verosimilitud cuando la distribución *a posteriori* resultante pertenece a la misma familia paramétrica que la distribución *a priori*. La principal ventaja de utilizar estas parejas es que transforma un problema complejo de integración en una simple operación aritmética: los parámetros de la *a posteriori* se obtienen sumando los conteos de los datos observados a los hiperparámetros originales.

Un ejemplo clásico es el modelo Beta-Binomial. Sea una variable aleatoria $Y \sim \text{Binomial}(n, \theta)$ con $\theta \sim \text{Beta}(\alpha, \beta)$, la distribución resultante es también una Beta, específicamente $\theta|y \sim \text{Beta}(\alpha + y, \beta + n - y)$.

¿Hace falta hacer un apartado y explicar al menos dos conjugadas con demostración?
Ejemplo beta-binomial caso univariado y dirichlet-multinomial para el multivariado, siento que no resta pero no suma tampoco ya que no se usa...

A pesar de su elegancia matemática, el uso exclusivo de distribuciones conjugadas puede resultar restrictivo, limitando la flexibilidad del modelado para representar fenómenos complejos. Cuando el cálculo analítico exacto de la distribución *a posteriori* resulta imposible, es necesario recurrir a métodos de aproximación.

5.1.4 Métodos de aproximación

En modelos bayesianos de alta dimensionalidad, como LDA, obtener la distribución *a posteriori* implica resolver una integral sobre el espacio conjunto de todos los parámetros (el denominador de Bayes). Esta operación es computacionalmente inviable excepto en casos triviales, razón por la cual la aplicación práctica de la inferencia bayesiana se vio históricamente limitada.

Sin embargo, con el avance de la capacidad computacional, surgieron métodos de aproximación estocástica. El objetivo central de estos algoritmos no es calcular la fórmula exacta de la distribución, sino obtener una muestra representativa de valores simulados que converjan a la distribución *a posteriori* objetivo.

5.1.4.1 Markov chain Monte Carlo

Un método de aproximación de la distribución *a posteriori* son las cadenas de Markov Monte Carlo (MCMC, por sus siglas en inglés) que, mediante un algoritmo iterativo, genera una secuencia de valores cuya distribución, después de un número suficiente de pasos, converge a la deseada.

El algoritmo hace uso de cadenas de Markov, un proceso donde el siguiente paso depende únicamente del paso actual (se le llama propiedad de falta de memoria). Matemáticamente $P(X_{t+1}|X_t, \dots, X_2, X_1) = P(X_{t+1}|X_t)$.

Existen algunos algoritmos MCMC que determinan cómo se dan los pasos, como metrópolis-hastings, hamiltonian Monte Carlo y Gibbs, que será descrita en detalle ya que se utiliza en la aplicación de LDA.

Para garantizar que el resultado de MCMC es fiable, se utilizan estadísticos de diagnóstico:

- $\hat{R}$ (estadístico de Gelman-Rubin): compara la varianza entre cadenas inicializadas en puntos dispersos con la varianza intra-cadena. Un $\hat{R} \approx 1$ implica una buena mezcla y convergencia.
- ACF (autocorrelación): mide la dependencia entre pasos sucesivos. Un alto valor de ACF implica una cadena ineficiente.
- ESS (tamaño efectivo de muestra): calcula el número de muestras independientes que equivalen a la cantidad de información obtenida de la muestra. Un ESS bajo en comparación al tamaño de la cadena implica un muestreo ineficiente.

5.1.4.2 Muestreo de Gibbs

El muestreo de Gibbs es un algoritmo iterativo que construya una secuencia dependiente de valores de parámetros. Se trata de un caso especial de metrópolis-hastings con una tasa de aceptación del 100% (nunca se rechazan las muestras). Opera explorando la condicionalidad.

$$p(x|y) = \frac{p(x, y)}{p(y)} \propto p(x, y)$$

Para ilustrar el algoritmo se plantea un caso bivariado para obtener la distribución de (x, y) . El algoritmo de Gibbs procede de la siguiente manera:

Paso 0 (inicialización): Se establecen valores iniciales arbitrarios para los parámetros, denotados como $(x^{(0)}, y^{(0)})$.

Paso s (Iteración): Para generar la muestra en la iteración s (donde $s = 1, 2, \dots$):

1. Actualización de x : Se genera un nuevo valor $x^{(s)}$ muestreando de su distribución condicional, condicionada al valor más reciente de y .

$$x^{(s)} \sim p(x \mid y^{(s-1)})$$

2. Actualización de y : Se genera un nuevo valor $y^{(s)}$ muestreando de su distribución condicional, condicionada al valor de x que acaba de ser actualizado en el paso anterior.

$$y^{(s)} \sim p(y \mid x^{(s)})$$

El par $(x^{(s)}, y^{(s)})$ constituye la nueva muestra de la cadena de Markov.

Este ciclo se repite un gran número de veces. Bajo condiciones de regularidad, la secuencia de pares generada $\{(x^{(s)}, y^{(s)})\}$ converge en distribución a la distribución conjunta objetivo $p(x, y)$. En la figura 4 se puede observar el caso presentado: las observaciones de (x, y) tienden a acercarse a la zona de alta probabilidad.




Figura 4: Exploración del espacio conjunto de (X, Y) mediante muestreo de Gibbs

5.2 Machine learning

El aprendizaje automático (*machine learning*, ML) es una rama de la inteligencia artificial que permite a las computadoras aprender patrones y tomar decisiones a partir de datos, sin ser programadas explícitamente para cada tarea. Es especialmente útil en problemas complejos, donde hay muchas reglas por seguir y/o entornos inconsistentes ya que los modelos de ML se adaptan fácilmente a nuevos datos.

Un ejemplo utilizado en lo cotidiano es el filtro de *spam* de la casilla de correo electrónico. Con algunos ejemplos de correos *spam* y correos legítimos o *ham* (datos de entrenamiento), el código detrás del filtro logra aprender la naturaleza de cada uno de estos elementos, logrando así clasificar nuevos casos. Los modelos de ML se evalúan con métricas de *performance* que se miden con datos de prueba.

Los sistemas de *machine learning* se pueden clasificar en función de la cantidad de supervisión que reciben en el entrenamiento entre supervisados y no supervisados.

En el aprendizaje supervisado, los modelos se entrenan con un conjunto de datos que ya cuenta con las respuestas del modelo (datos de entrenamiento). Por ejemplo, si un filtro de *spam* recibe correos con la etiqueta *spam* y *no spam* en el entrenamiento, se está hablando de un aprendizaje supervisado. Entre las técnicas más importantes del aprendizaje supervisado se encuentran *k-nearest neighbors* (KNN), regresión lineal, regresión logística, *support vector machine* (SVM), árboles de decisión, *random forest*, redes neuronales, etc.

En el aprendizaje no supervisado, los datos de entrenamiento no cuentan con etiquetas, se dice que el sistema intenta aprender sin profesor. Por ejemplo, si se quisiera agrupar a clientes de un negocio según su consumo, el algoritmo detecta las similitudes y diferencias entre ellos y define un agrupamiento que será evaluado con las métricas de *performance* y ajustado según su resultado.

5.3 Procesamiento de Lenguaje Natural (NLP)

El texto, tal como lo leemos y comprendemos los humanos, es rico en significado pero carece de una estructura numérica, que es la base del procesamiento en los algoritmos de aprendizaje automático. El procesamiento de lenguaje natural es un área de investigación dentro de la informática y la inteligencia artificial (IA) que se ocupa de procesar el lenguaje humano. Este procesamiento generalmente implica traducir el lenguaje natural en datos (números) que una computadora puede usar para aprender sobre el mundo.

El proceso abarca tareas como la recolección, limpieza, normalización y tokenización de texto, estas últimas dos son las responsables de que la información textual pueda ser estructurada de manera que los modelos la interpreten y analicen eficazmente. En la Figura 5 (Vajjala et al., 2020) se pueden observar los pasos que comprende el proceso.




Figura 5: Etapas del NLP

Aunque no sea evidente, el procesamiento de lenguaje natural (NLP) aparece en el día a día de las personas. Tiene una amplia variedad de aplicaciones prácticas, lo que lo convierte en una herramienta esencial en diversos campos, por ejemplo:

- mejoras en motores de búsqueda web,
- corrección ortográfica durante la búsqueda,
- revisión gramatical y ortográfica,
- desarrollo de chatbots y asistentes virtuales,
- generación de índices y tablas de contenido,
- filtrado de spam en correo electrónico,
- personalización en campañas de marketing.

Este amplio rango de usos subraya su importancia como puente entre los lenguajes humanos y las capacidades computacionales.

5.3.1 Recolección de datos

El primer paso esencial en cualquier proyecto de procesamiento de lenguaje natural es la recolección de datos. Esta etapa determina la calidad y relevancia de los resultados que se obtendrán al aplicar técnicas avanzadas como latent Dirichlet allocation (LDA). Existen diferentes enfoques para recopilar datos en NLP, dependiendo de los objetivos del análisis y la disponibilidad de recursos. A continuación, se describen las principales estrategias de recolección de datos:

Uso de conjuntos de datos públicos

Una opción inicial es buscar conjuntos de datos públicos que sean relevantes para la tarea específica. Si el conjunto de datos es adecuado, se puede proceder directamente a construir y evaluar un modelo. Sin embargo, cuando no se encuentra un dataset que cumpla los requisitos, se debe considerar generar datos personalizados.

Obtención de datos de internet

Otra estrategia consiste en identificar fuentes relevantes de datos en internet, como foros de consumidores o plataformas de discusión donde se publiquen consultas. Estos datos pueden ser extraídos automáticamente a través de técnicas de *web scraping* y, posteriormente, etiquetados manualmente por anotadores humanos.

Combinación de fuentes de datos

En la práctica, los conjuntos de datos suelen provenir de fuentes heterogéneas, como *datasets* públicos, datos etiquetados manualmente y datos de internet, al mismo tiempo. Esta combinación es especialmente útil para construir modelos en etapas iniciales, cuando los datos específicos para un escenario particular son limitados.

En esta tesina se optó por hacer uso de una *API* de Google para obtener los datos de entrada para el análisis, este proceso será detallado en la sección ??.

Esta etapa es crucial para garantizar la disponibilidad de datos limpios y útiles, que son la base para las siguientes etapas de procesamiento y modelado. Una vez que se cuenta con los datos recolectados, se procede al siguiente paso: la limpieza y el preprocesamiento de texto.

5.3.2 Limpieza de texto

La extracción y limpieza de texto se refiere al proceso de extraer de los datos de entrada el texto sin procesar, eliminando toda la información no textual, como marcas, metadatos, etc., y convirtiéndolo al formato de codificación requerido. La extracción de texto es un paso estándar en el manejo de datos y, usualmente, no emplea técnicas específicas de NLP. Sin embargo, es un paso importante que tiene implicaciones para todos los demás aspectos. Además, también puede ser la parte más demandante en términos de tiempo dentro de

un proyecto.

Pasos preliminares

Previo a la limpieza del texto, es necesario llevar a cabo una serie de transformaciones básicas que garanticen la homogeneidad del corpus. En primer lugar, se convierte todo el texto a minúsculas con el fin de evitar que palabras idénticas sean tratadas como distintas debido a diferencias en el uso de mayúsculas, por ejemplo, “Video” y “video”. Otro paso fundamental consiste en la eliminación de signos de puntuación, caracteres especiales y espacios innecesarios, que no aportan información semántica al análisis y pueden generar una dispersión artificial en el vocabulario. En esta etapa también se contempla la reducción de espacios múltiples a un único espacio, asegurando así una identificación más precisa de las palabras.

Finalmente, se corrigen patrones de escritura característicos de entornos informales, como la repetición exagerada de letras para enfatizar una emoción (por ejemplo, “amoo” en lugar de “amo” o “encantaa” en lugar de “encanta”). Este tipo de modificaciones, frecuentes en comentarios de redes sociales, pueden aumentar la longitud del vocabulario y dificultar la identificación de términos representativos. La normalización de estas formas al estándar correspondiente resulta clave para mejorar la coherencia interna del corpus y facilitar los pasos posteriores de análisis.

Tokenización

La tokenización es un paso fundamental en el procesamiento del lenguaje natural que tiene como objetivo transformar el texto libre en una secuencia de unidades discretas que puedan ser procesadas computacionalmente. Consiste en segmentar el texto en unidades mínimas llamadas tokens, cuya definición depende de la granularidad aplicada en el proceso:

- A nivel de palabra: cada token corresponde a una palabra. Ejemplo: “Muy bueno el video” → [“Muy”, “bueno”, “el”, “video”].
- A nivel de sub-palabra: cada token es un fragmento de una palabra. Ejemplo: “jugando” → [“jug”, “ando”].
- A nivel de carácter: cada token es un único carácter (letra, signo de puntuación, número, etc.). Ejemplo: “sol” → [“s”, “o”, “l”].
- A nivel de oración: cada token corresponde a una oración completa. Ejemplo: “Hoy llueve. Mañana saldrá el sol.” → [“Hoy llueve.”, “Mañana saldrá el sol.”].

Normalización de unicode

Al limpiar texto, especialmente que se ha obtenido a través de *web scrapping*, es posible que se encuentren varios caracteres *unicode*, incluidos símbolos, emojis y otros caracteres gráficos, algunos ejemplos se muestran

en la Figura 6 (Vajjala et al., 2020).



Figura 6: Caracteres Unicode y su representación gráfica

Para interpretar estos símbolos no textuales y caracteres especiales se utiliza la normalización de *unicode*, que convierte el texto en alguna forma de representación binaria para ser almacenado en una computadora. Existen varios esquemas de codificación, y la codificación predeterminada puede variar según el sistema operativo. En términos generales, se eliminan todos los caracteres que no pertenecen al alfabeto.

Eliminación de stopwords

Las *stopwords* son palabras funcionales que, si bien cumplen un rol gramatical importante (como preposiciones, artículos, pronombres...), no aportan contenido semántico relevante al análisis del significado global del texto.

El objetivo de esta etapa es reducir el ruido lingüístico y centrar el análisis en las palabras que efectivamente comunican información. Por ejemplo, en frases como "gracias por el dato" o "esto es una joya", las palabras *por*, *el*, *es*, *una* son típicamente consideradas *stopwords*, mientras que *gracias*, *dato*, *joya* son términos de interés.

Para llevar a cabo esta tarea se utilizará el paquete *tm* (*Text mining*) que cuenta con un listado de *stopwords* (Tabla 1) y funciones como `removeWords` que permite eliminarlas de un texto dado.

Tabla 1: Algunas stopwords del paquete

de	la	que	el	en	y	a	los	del	se
las	por	un	para	con	no	una	su	al	lo

Corrección ortográfica

La corrección de errores en la escritura es un aspecto fundamental del procesamiento del lenguaje natural ya que los textos pueden contener diferentes tipos de fallos que afectan su comprensión y coherencia. Los

errores en la redacción pueden clasificarse en tres categorías principales (*Moyotl-Hernández, 2016*):

- Errores ortográficos: ocurren cuando una palabra escrita no existe dentro del idioma.
- Errores gramaticales: Se presentan cuando las palabras utilizadas existen en el idioma, pero no son correctas en el contexto de la oración.
- Errores de estilo: se refieren a palabras redundantes, ambiguas o repetidas que afectan la claridad del texto.

En este sentido, un corrector ortográfico tiene como objetivo identificar palabras mal escritas dentro de un texto y sugerir la opción más adecuada a partir de un conjunto de términos válidos en el idioma.

Corrección ortográfica empleando distancia de Levenshtein-Damerau

La distancia de Levenshtein o distancia de edición es una medida utilizada para calcular la similitud entre palabras, se trata de un conteo de operaciones requeridas para convertir una cadena de caracteres (una palabra) en otra. Las operaciones de edición son:

- Intersección de un caracter: *hogr* $\rightarrow$ *hogar* (agregar ‘a’ entre la ‘h’ y la ‘g’).
- Eliminación de un caracter: *argentina* $\rightarrow$ *argentina* (eliminar la ‘g’).
- Sustitución de un caracter por otro: *numero* $\rightarrow$ *número* (reemplazar la ‘u’ por la ‘ú’).

Hay una generalización de esta medida que considera el intercambio de dos caracteres como una operación: la distancia de Levenshtein-Damerau. En este método, aparece:

- Transposición de caracteres: *paelta* $\rightarrow$ *paleta* (intercambia el lugar de la ‘e’ y la ‘l’).

El método de corrección basado en la distancia de Levenshtein-Damerau se fundamenta en la búsqueda de la palabra más similar dentro de un diccionario para corregir una palabra mal escrita. Este procedimiento implica generar todas las posibles transformaciones de la palabra errónea mediante las operaciones de edición. Luego, cada una de estas transformaciones se compara con las palabras existentes en el diccionario, y aquellas que coincidan se agregan a una lista de sugerencias. Finalmente, la mejor corrección será aquella con la menor distancia a la palabra original.

En la Tabla 2 se muestran todas las palabras generadas a partir de la palabra errónea **burri** con una sola operación de edición.

Tabla 2: Posibles transformaciones de la palabra burri con distancia de edición uno

Operación	Palabras generadas
Eliminación	urri, brri, buri, bur
Inserción	aburri, bburri, cburri, ..., zburri, burris, burria, ..., burriz
Sustitución	aurri, burrs, murri, ..., burro, burrq, ..., burrz
Transposición	ubrri, bruri, burir

El desafío radica en seleccionar la cantidad de operaciones admitidas para la corrección y cuál de estas opciones es la más apropiada. En el siguiente código se define un diccionario ficticio para este caso y se calcula la distancia L-D haciendo uso del paquete `stringdist` para cada palabra del mismo. En la Tabla 3 se observan los resultados.

```
# Paquetes
library(stringdist)
library(dplyr)

# 1. Token a corregir
token <- "burri"

# 2. Diccionario ficticio
diccionario <- c("burro", "burrito", "barri", "burla",
                 "perro", "aburris", "aburro", "caballo")

# 3. Calculamos distancia DL
resultados <- tibble::tibble(
  candidato = diccionario,
  distancia = stringdist(token, diccionario, method = "dl")
) %>%
  arrange(distancia, candidato)
```

Tabla 3: Posibles correcciones para la palabra 'burri'

Candidato	Distancia	Candidato	Distancia
barri	1	burla	2
burro	1	burrito	2
aburris	2	perro	3
aburro	2	caballo	6

Si bien es fácil identificar que **perro** o **caballo** no son buenas correcciones, observando el resultado de la distancia L-D se llega a la misma conclusión. Para este conjunto de datos y el ejemplo en particular, hay correcciones mejores en función de este cálculo.

En síntesis, el uso de la distancia de Levenshtein-Damerau constituye una herramienta potente para la corrección ortográfica, ya que permite identificar palabras candidatas a partir de criterios formales de similitud. No obstante, los desafíos principales radican en establecer un umbral de tolerancia adecuado y en gestionar la carga computacional asociada. Una tolerancia demasiado estricta puede dejar sin corregir errores evidentes, mientras que una tolerancia demasiado laxa puede introducir correcciones incorrectas. A su vez, el proceso de comparar un término erróneo contra todas las palabras de un diccionario extenso es computacionalmente intensivo. De igual modo, disponer de un diccionario amplio, representativo y ajustado al dominio del corpus resulta esencial para que las sugerencias tengan sentido lingüístico y contextual. En conjunto, ambos elementos, son determinantes para perfeccionar los procesos de corrección ortográfica y garantizar resultados confiables en etapas posteriores del análisis de texto.

Lematización

La lematización es un proceso de normalización léxica en NLP cuyo objetivo es reducir las palabras a su forma canónica o “lema”. Al aplicar lematización:

- Se eliminan variaciones flexivas (tiempo verbal, número, género).
- Se conserva el significado léxico de la palabra.
- Se mejora la coherencia del vocabulario al reducir distintas formas a un único término.

El paquete **UDPipe** implementa modelos de *Universal Dependencies* que permiten realizar tokenización, etiquetado gramatical y lematización de textos en múltiples lenguas.

```
library(udpipe)
udmodel <- udpipe_load_model("spanish-gsd-ud-2.5-191206.udpipe")
texto <- c("Los estudiantes estaban estudiando en la biblioteca.")
anot <- udpipe_annotate(udmodel, x = texto, doc_id = 1)
```

Tabla 4: Salida de UDPipe: tokens, lemas y categorías gramaticales

Token	Lema	UPOS
Los	el	DET
estudiantes	estudiante	NOUN
estaban	estar	AUX
estudiando	estudiar	VERB
en	en	ADP
la	el	DET
biblioteca	biblioteca	NOUN
.	.	PUNCT

En la Tabla 4 se observan los resultados de la lematización con una oración simple. El código devuelve palabras separadas, los lemas correspondientes y el tipo de palabra procesada, entre ellas:

- DET: determinante.
- NOUN: sustantivo.
- VERB: verbo.
- ADP: adposición.
- PUNCT: puntuación.

Estos son algunos de los tipos de palabras que el paquete `UDPipe` reconoce. Este etiquetado permite filtrar aquellas categorías con mayor carga semántica (sustantivos, verbos, adjetivos, adverbios y nombres propios) y así disminuir la dimensionalidad de la entrada del modelo.

5.3.3 Representación de texto

La extracción de características relevantes (*feature extraction*) es un paso clave para el procesamiento de texto, ya que incluso el mejor modelo de *machine learning* devuelve resultados pobres si la información de entrada es inadecuada. En este apartado se desarrollarán algunas técnicas para transformar texto en una representación numérica robusta que pueda alimentar un algoritmo correctamente.

Representación vectorial

La representación vectorial de un texto consiste en la transformación de una palabra u oración a un vector de números reales dentro de un espacio vectorial de n dimensiones. Esta transformación se realiza a través de un modelo matemático y el vector resultante sirve para cuantificar las similitudes y diferencias entre dos

fragmentos de texto. La manera más común de medir esta comparación es a través de la similitud coseno (o coseno del ángulo entre vectores).

Dados dos vectores, A y B , cada uno con n componentes, la similitud coseno se calcula como:

$$\cos(\theta) = \frac{A \cdot B}{|A||B|}$$

Un resultado de 1 implica similitud total (el ángulo θ es 0), y un resultado de -1 implica diferencia total (el ángulo θ es 180). Además de la similitud coseno, la distancia euclídea es otra métrica frecuente para medir la proximidad o lejanía entre vectores.

One-Hot Encoding

Una de las formas más sencillas y fundamentales de representar texto numéricamente es mediante la codificación *One-Hot*. En este enfoque, cada palabra v del corpus V se asocia a un identificador único y se representa como un vector binario de tamaño igual a V . Este vector está compuesto de todos ceros, excepto en la posición correspondiente a la palabra en el vocabulario, donde se ubica un 1.

Para ilustrar, se considera el siguiente corpus:

- D1: El perro muerde.
- D2: El gato muerde.
- D3: El perro ladra.
- D4: El gato maúlla.

Luego de preprocesar el texto, el vocabulario resultante está compuesto por cinco palabras únicas:

"perro", "muerde", "gato", "ladra", "malla"

A cada palabra de este se le asigna un índice único y será representada como un vector binario de longitud 5.

$$perro \rightarrow [1, 0, 0, 0, 0]; \dots; ladra \rightarrow [0, 0, 0, 1, 0]; malla \rightarrow [0, 0, 0, 0, 1]$$

Entonces, la oración D1: "El perro muerde" se representa con *One-Hot encoding* como la matriz:

$$\begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \end{bmatrix}$$

Si bien es un método simple, presenta dos desventajas principales: la alta dimensionalidad y la falta

de información semántica, ya que la distancia coseno entre cualquier par de palabras distintas es 0 ya que las matrices resultan ortogonales.

Bag of words

Una de las representaciones más clásicas del texto es el enfoque *bag of words* (BoW). Este método trata a un documento como una bolsa de palabras, ignorando su orden sintáctico, pero manteniendo un registro de la frecuencia con la que aparece cada término. La intuición detrás de BoW es que la frecuencia de ciertos términos puede caracterizar el contenido de un documento.

Al igual que en *One-Hot encoding*, BoW asigna un identificador único a cada palabra del vocabulario. Luego, representa cada documento como un vector de longitud igual al tamaño del vocabulario, donde el valor en cada posición indica cuántas veces aparece esa palabra en el documento.

Tomando el ejemplo anterior, la representación BoW para la primera oración (El perro muerde) es $[1, 1, 0, 0, 0]$. Los documentos se vuelven comparables en función de su contenido léxico, como se observa en la Figura 7: los documentos D1 y D2 tienen mayor similitud ya que comparten el término *muerde*, también D1 y D3 porque comparten el término *perro*.




Figura 7: Similitud entre las oraciones analizadas con BoW utilizando la similitud coseno

TF-IDF

TF-IDF (*Term Frequency-Inverse Document Frequency*) es una técnica fundamental que refina BoW al asignar pesos distintos a las palabras, destacando la importancia de aquellas que son relevantes en un documento específico pero raras en el conjunto total de documentos (corpus).

El valor TF-IDF para una palabra t en un documento d se calcula como el producto de dos componentes:

$$TF-IDF(t, d) = TF(t, d)IDF(t)$$

Donde:

- TF mide la frecuencia de un término en un documento, normalizada por la cantidad total de términos en ese documento:

$$TF(t, d) = \frac{\text{Nº ocurrencias de } t \text{ en } d}{\text{Total de términos en } d}$$

- IDF mide la rareza de una palabra a lo largo de todos los documentos. Esta métrica penaliza los términos comunes (como artículos o preposiciones) y valora los poco frecuentes, lo que aumenta su poder discriminatorio:

$$IDF(t) = \log\left(\frac{\text{Nº total de documentos}}{\text{Nº de documentos donde aparece } t}\right)$$

Para el ejemplo de las 4 oraciones, un término como “perro” aparece en dos documentos, por lo que su IDF es más bajo que el de un término como “ladra”, que aparece solo una vez. Esto hace que “ladra” sea más relevante para el documento D3 que lo que es “perro” para D1. En la Tabla 5 se puede observar el resultado del cálculo detallado que realiza la técnica para las 4 oraciones.

Tabla 5: Cálculo de TF-IDF para cada documento

0.5	0.5	0.0	0	0
0.5	0.0	0.5	0	0
0.0	0.5	0.0	1	0
0.0	0.0	0.5	0	1

En comparación con BoW, TF-IDF logra una diferenciación más fina entre documentos al asignar

menor peso a palabras frecuentes, lo que resulta en una matriz de similitud como la que se visualiza en la Figura 8. Los documentos D2 y D4 tienen menos similitud entre sí que D2 y D1, ya que este segundo par comparte el término *muerde* que es menos frecuente que *gato*.



Figura 8: Similitud entre las oraciones analizadas con TF-IDF utilizando la similitud coseno

Embeddings

En el campo del Procesamiento del Lenguaje Natural, los *embeddings* (incrustaciones vectoriales) han transformado la representación de texto. A diferencia de las representaciones esparsas y de alta dimensionalidad como *One-Hot* y TF-IDF, los embeddings producen representaciones vectoriales densas y compactas que capturan relaciones semánticas complejas.

Un embedding es esencialmente un vector numérico de tamaño fijo que encapsula el significado de una palabra en un contexto lingüístico. Estas representaciones permiten que palabras con significados similares se encuentren cercanas en el espacio vectorial. La base de esta técnica es la hipótesis distribucional, que establece que “el significado de una palabra está determinado por las palabras con las que co-ocurre”.

Word2Vec

Word2Vec, propuesto por Mikolov et al. (2013), marcó un hito al ofrecer una manera eficiente de generar representaciones vectoriales densas para palabras que capturan relaciones semánticas y sintácticas. *Word2Vec* utiliza redes neuronales poco profundas y ofrece dos arquitecturas principales:

- *Continuous Bag of Words* (CBOW): Predice la palabra central (w_t) a partir del contexto circundante. Es computacionalmente eficiente y funciona bien en corpus más pequeños.
- *Skip-gram*: Predice las palabras de contexto a partir de una palabra central (w_t). Es más efectivo para capturar relaciones semánticas en corpus grandes y complejos.

Ambas arquitecturas se basan en minimizar una función de pérdida que optimiza la probabilidad de predecir correctamente palabras dentro de una “ventana de contexto”.

GloVe

GloVe (*Global Vectors for Word Representation*), presentado por Pennington et al. en 2014, surgió como un enfoque híbrido que combina las ventajas de los modelos predictivos locales (*Word2Vec*) y las estadísticas de co-ocurrencia globales del corpus.

A diferencia de *Word2Vec*, que se entrena solo con ventanas locales, *GloVe* optimiza una función de costo que relaciona directamente el producto escalar de los vectores de dos palabras ($w_i^T \tilde{w}_j$) con el logaritmo de su frecuencia de co-ocurrencia en todo el corpus ($\log X_{ij}$).

La función de costo de GloVe se define como:

$$J = \sum_{i=1}^V \sum_{j=1}^V f(X_{ij})(w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij})^2$$

Donde X_{ij} es el número de veces que la palabra j aparece en el contexto de la palabra i , y $f(X_{ij})$ es una función de ponderación que gestiona la importancia de las co-ocurrencias. Al incorporar esta información global (la matriz de co-ocurrencia), *GloVe* logra una representación vectorial que refleja de manera más robusta la estructura semántica de todo el conjunto de datos.

BERT

Con la introducción de *BERT* (*Bidirectional Encoder Representations from Transformers*) por Devlin et al. en 2018, la representación de texto experimentó un cambio fundamental, pasando de embeddings estáticos (como *Word2Vec* y *GloVe*) a embeddings contextuales. *BERT* se basa en la arquitectura *Transformer*, la cual utiliza mecanismos de auto-atención para evaluar las dependencias entre todas las palabras de una secuencia simultáneamente.

La innovación clave de *BERT* es su capacidad de entrenamiento bidireccional. El modelo procesa la secuencia completa, permitiendo que la representación vectorial de una palabra se base en el contexto que le precede y el que le sigue. Esto resuelve la ambigüedad semántica que presentaban los otros métodos, ya que el modelo captura el significado específico de una palabra con el contexto y no lo toma como un elemento aislado.

El modelo se preentrena sobre grandes volúmenes de texto mediante dos tareas:

- *Masked Language Model* (MLM): Se enmascara una fracción de palabras al azar y el modelo debe predecir las palabras ocultas. Esta tarea obliga a *BERT* a aprender representaciones bidireccionales profundas.
- *Next Sentence Prediction* (NSP): El modelo recibe dos oraciones y debe predecir si la segunda sigue lógicamente a la primera. Esto entrena a *BERT* a comprender las relaciones entre oraciones.

BERT produce embeddings dinámicos de alta dimensionalidad. Además de generar representaciones, el modelo es diseñado para ser ajustado (fine-tuned) con una pequeña cantidad de datos específicos de la tarea.

6 Bibliografía

- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993-1022.
- El Economista. (2024). *Streaming en Argentina: cuáles son los canales líderes y cómo monetizan sus contenidos*. <https://eleconomista.com.ar/sociedad-redes/streaming-2024-argentina-canales-lideres-figuras-estrategias-monetizacion-n74497>.
- GÉRON, A. (2019). *stringdist: Handson machine learning with scikitlearn, keras & tensorflow*. http://14.139.161.31/OddSem-0822-1122/Hands-On_Machine_Learning_with_Scikit-Learn-Keras-and-TensorFlow-2nd-Edition-Aurelien-Geron.pdf
- Kruschke, J. K. (2014). *Doing Bayesian data analysis : a tutorial with R, JAGS, and Stan*.
- Loo, M. van der. (2025). *stringdist: Approximate String Matching and String Distance Functions*. <https://cran.r-project.org/web/packages/stringdist/stringdist.pdf>
- Moyotl-Hernández, E. (2016). Método de corrección ortográfica basado en la frecuencia de las letras. *Research in Computing Science*, 124, 145-156.
- Vajjala, S., Majumder, B., Gupta, A., & Surana, H. (2020). *Practical Natural Language Processing*. O'Reilly Media.